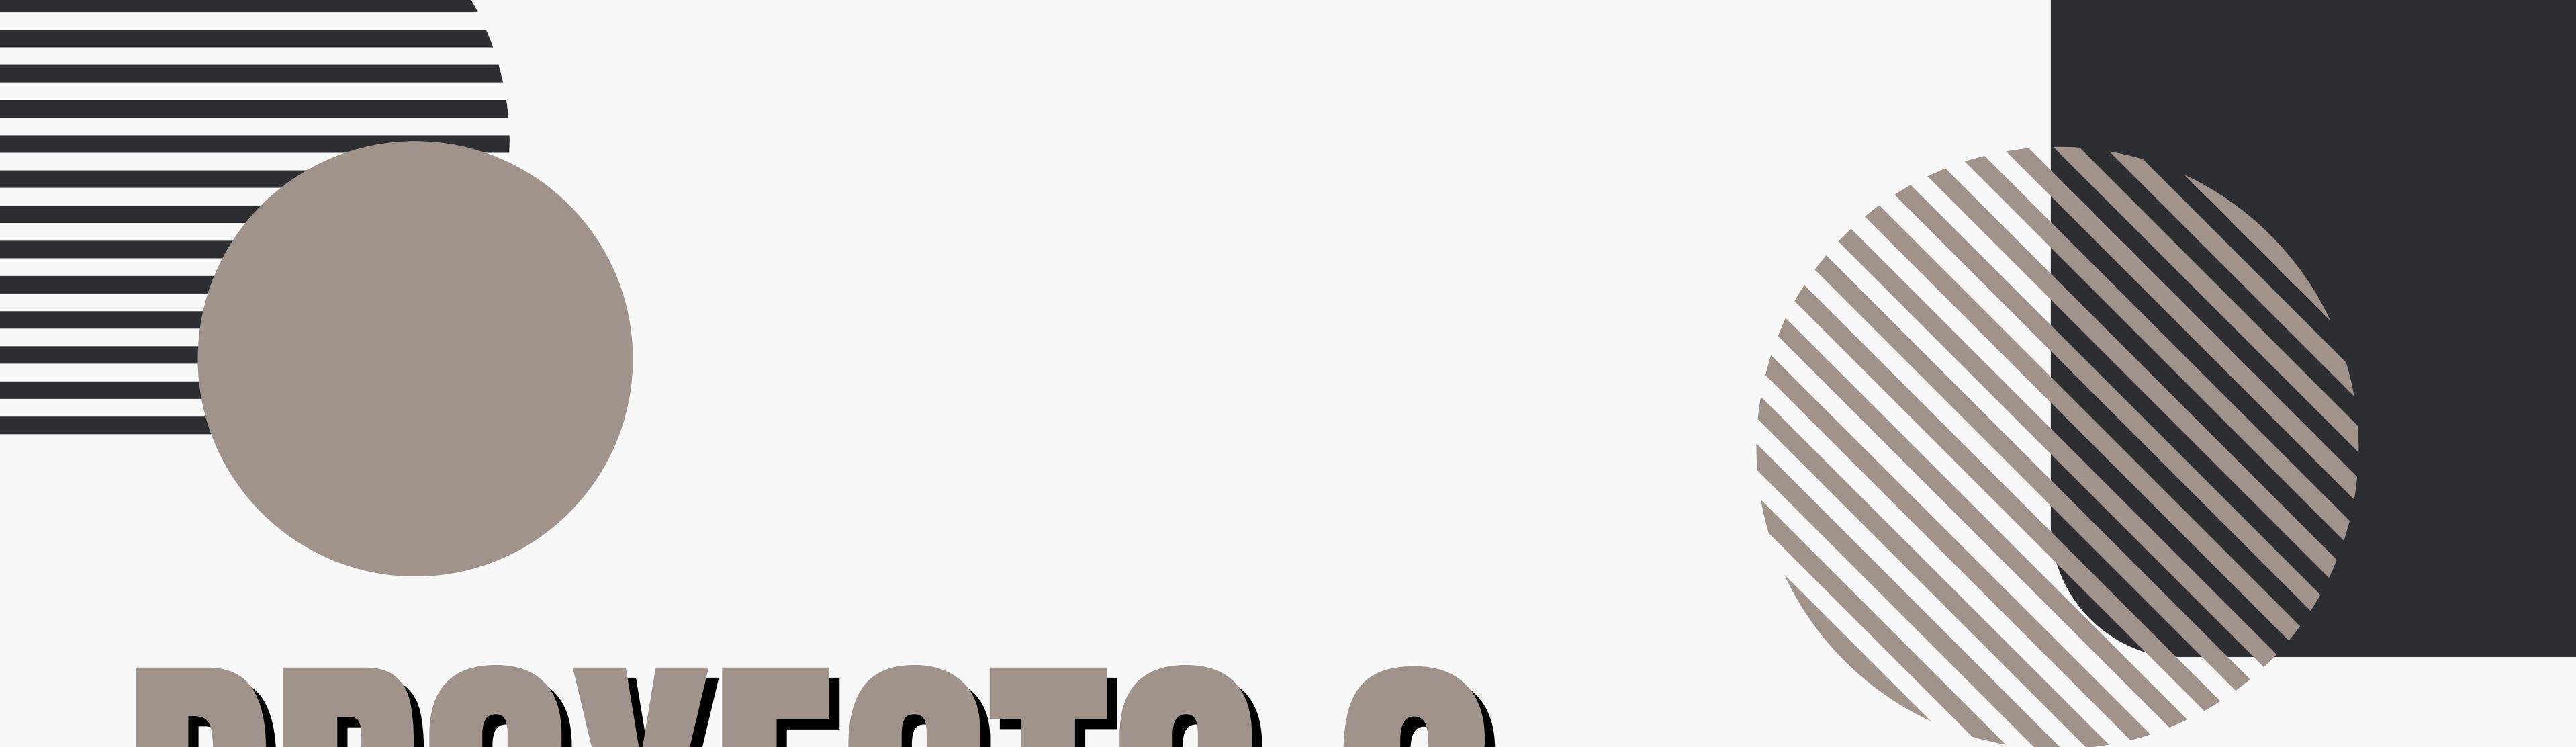


PROYECTO 2

GRUPO



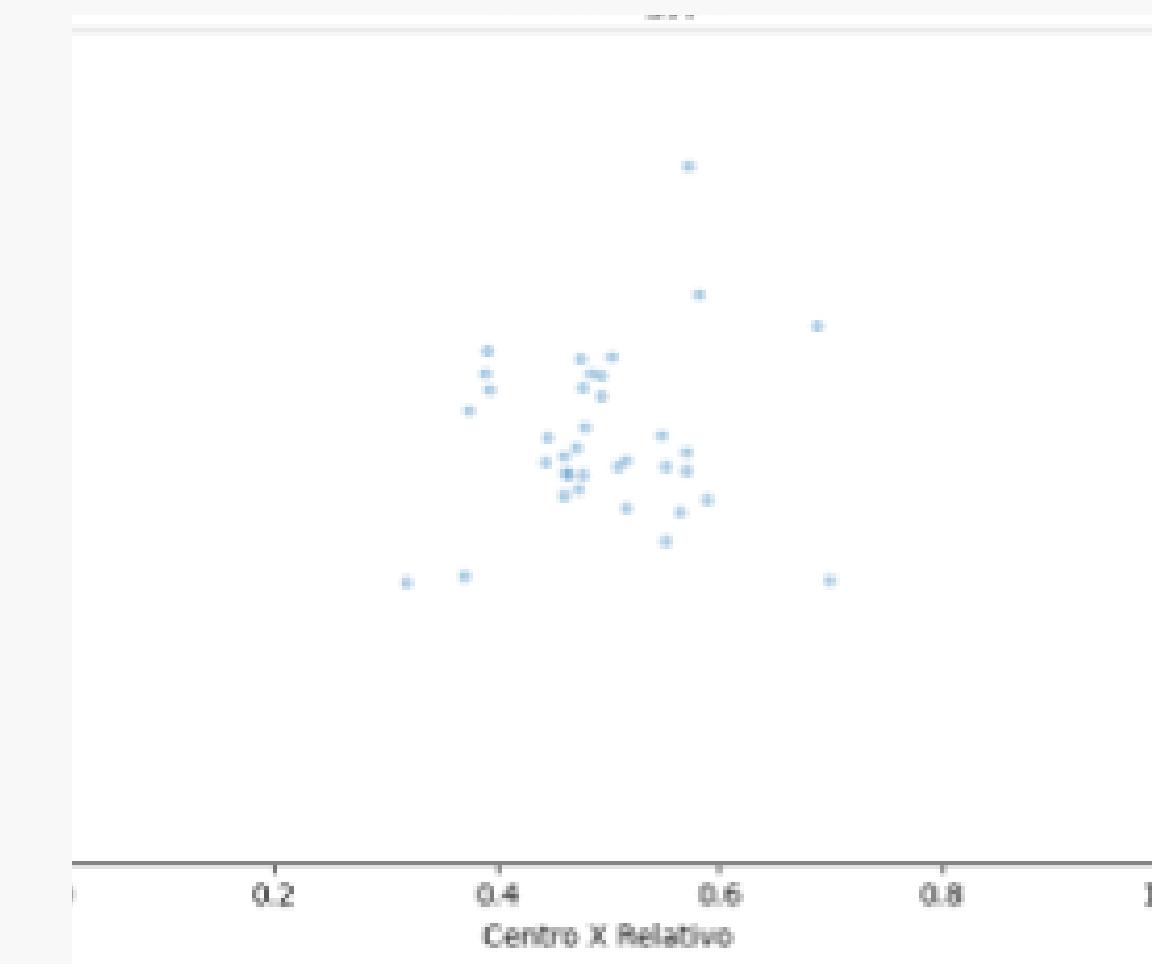
INTRODUCCION

En este proyecto, trabajamos sobre un dataset de clasificación de mosquitos. Este fue parte de un desafío competencia pública, llamada el Mosquito Alert Challenge. El dataset consta de imágenes de mosquitos con bounding boxes, image size y un nombre de archivo. El objetivo es implementar modelos de visión por computadora para lograr identificar la región donde se encuentra el mosquito, al igual que clasificarlo dentro de las diferentes especies



EDA

Durante el EDA, encontramos un fuerte desbalance clases. Esto no nos genera únicamente el problema de una representación minoritaria, sino que también una falta en variación de posiciones de las clases más pequeñas.



PIPELINE

Dentro del pipeline de preprocessamiento, transformamos las imágenes para tener tamaños uniformes a lo largo de todas las imágenes del dataset. Luego, para el conjunto de pruebas realizamos data augmentation con transformaciones de rotación y posición. Esto nos ayuda a que el modelo pueda generalizar de una mejor manera. Adicionalmente, utilizamos un WeightedRandomSampler para asegurarnos que las clases minoritarias no se vieran afectadas.



FASTER R-CNN

Descripción

- Modelo de detección de dos etapas que primero propone regiones de interés y luego clasifica los objetos dentro de ellas.
- Destaca por su alta precisión y fiabilidad, siendo ideal para aplicaciones científicas o de laboratorio donde la exactitud es prioritaria.

Métrica	Score
Mean IoU	0.715
Precision	0.906
Recall	0.838
F1-Score	0.871

Datos clave

- Se entrena de manera end-to-end con una sola pérdida combinada.
- Aunque más lento que los detectores de una etapa, logra la mayor precisión y robustez.



RETINANET

Descripción

- Detector de una sola etapa que introduce la Focal Loss, una función que mejora el aprendizaje cuando hay mucho fondo y pocos objetos reales.
- Ofrece un equilibrio entre precisión y eficiencia, útil para datasets desbalanceados o tareas generales de detección.

Métrica	Score
Mean IoU	0.814
Precision	0.456
Recall	0.498
F1-Score	0.476

Datos clave

- Mejora el rendimiento de los detectores de una sola etapa sin sacrificar velocidad.
- La FPN permite detectar objetos de distintos tamaños con la misma red.
- Requiere menos memoria y tiempo que Faster R-CNN.

SSD

Descripción

- Realiza detección en una sola pasada de la red, usando múltiples escalas para reconocer objetos grandes y pequeños simultáneamente.
- Es un modelo rápido, liviano y fácil de implementar, ideal para detección en tiempo real

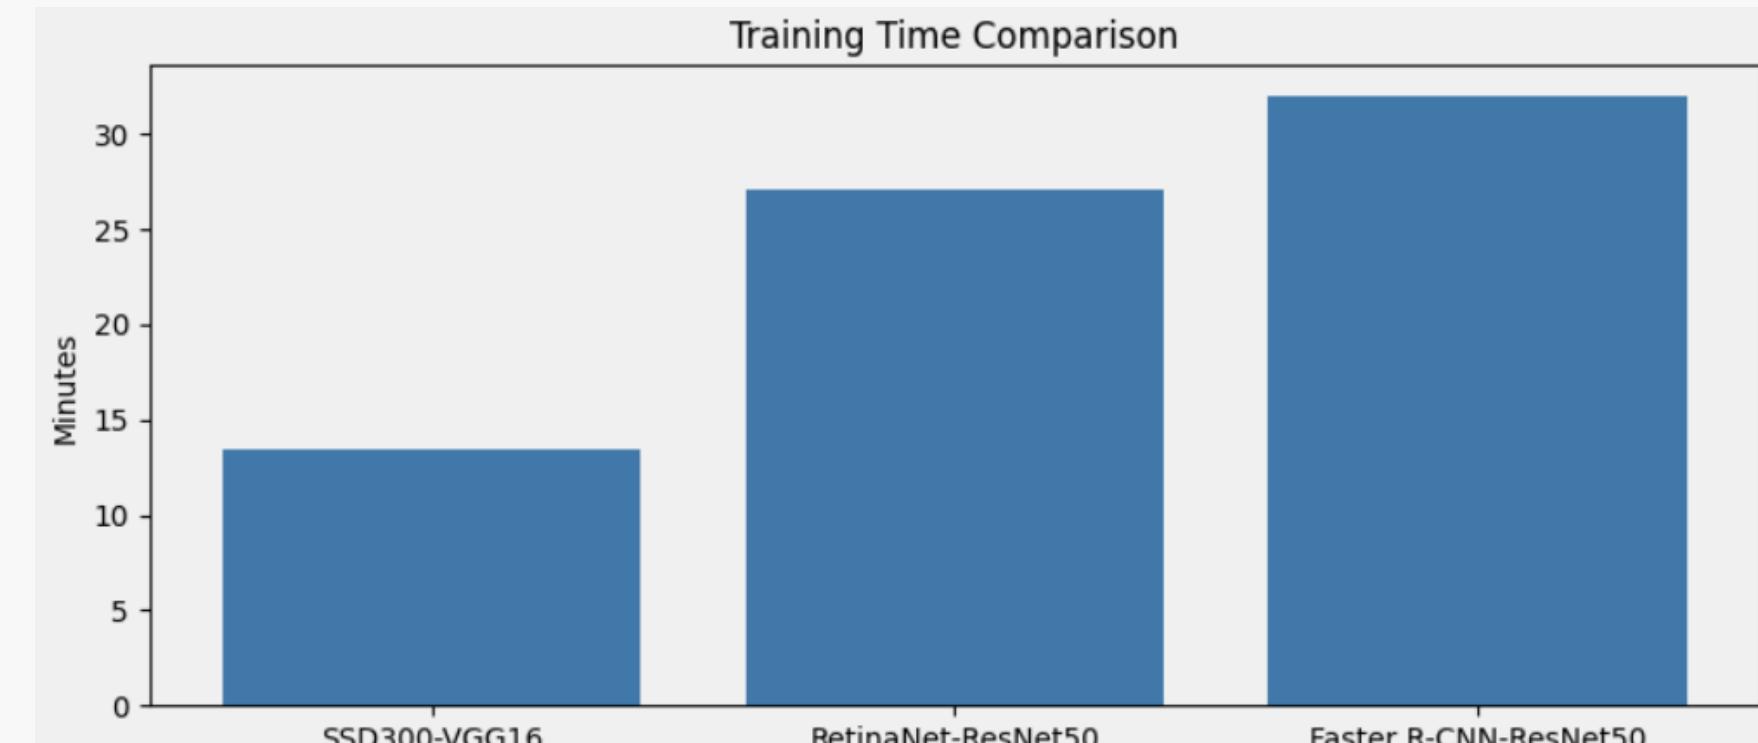
Métrica	Score
Mean IoU	0.672
Precision	0.554
Recall	0.019
F1-Score	0.037

Datos clave

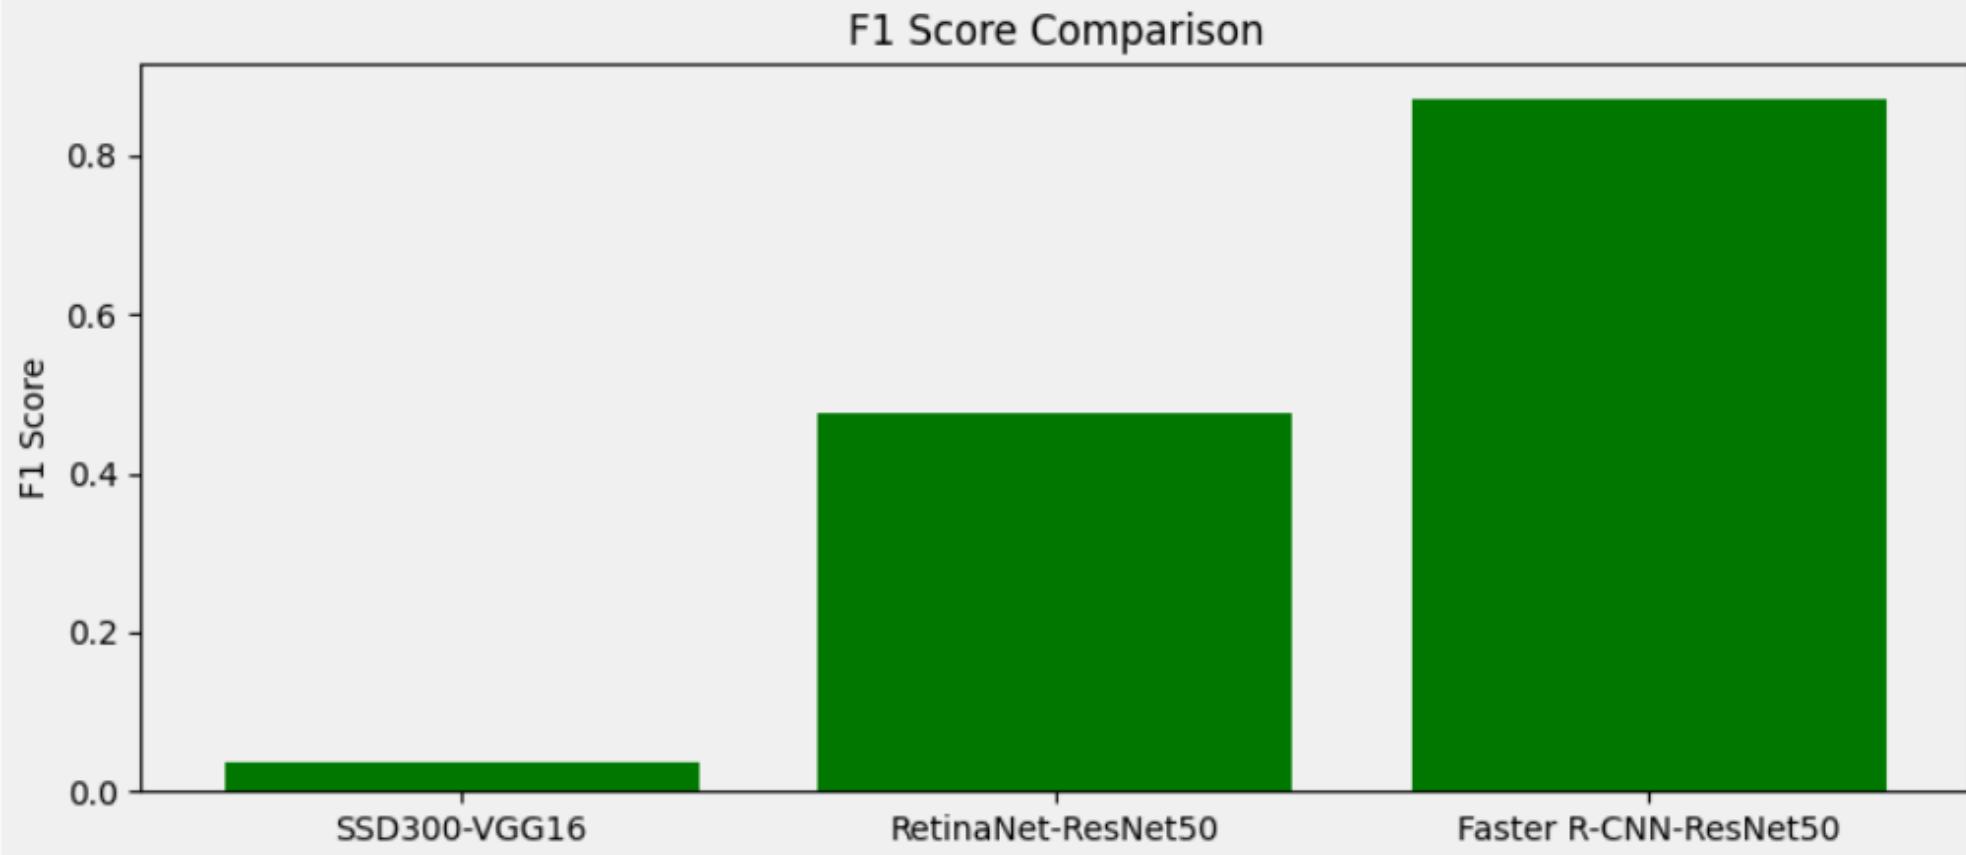
- No necesita una red de propuestas de regiones.
- Muy eficiente en tiempo de inferencia.

COMPARATIVA

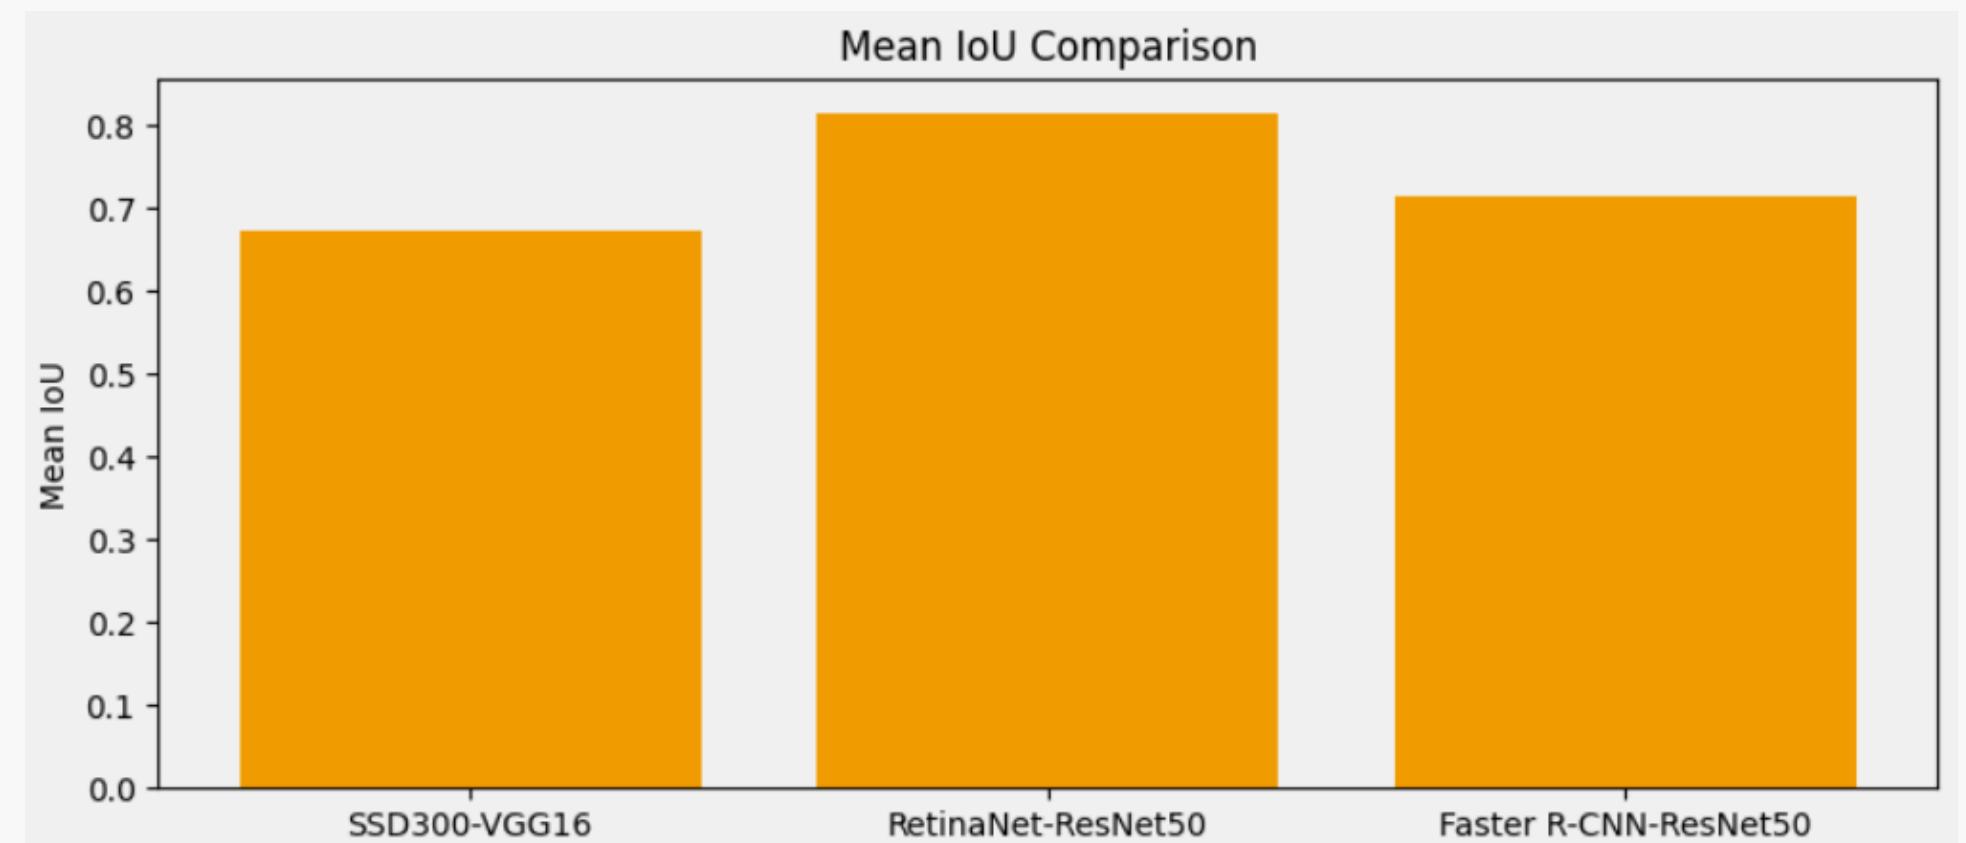
Training Time Comparison



F1 Score Comparison



Mean IoU Comparison



CONCLUSIONES

- El modelo SSD300 a pesar de ser rapido, probó no se capaz de resolver el problema bajo las condiciones de entrenamiento del proyecto.
- Los modelos de RetinaNet y Faster R-CNN comprobaron ser efectivos para resolver el problema, sin embargo ambos destacaron en áreas diferentes.
- La mejor clasificación se dio en Faster R-CNN, mientras que la mejor identificación de objetos fue RetinaNet. Se puede considerar un enfoque híbrido, donde se trabajan completamente por separado estas dos características.





MUCHAS GRACIAS